



UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE
CENTRO DE TECNOLOGIA
CURSO DE ENGENHARIA DE TELECOMUNICAÇÕES

VÍTOR GABRIEL LEMOS LOPES

MACHINE LEARNING OPERATIONS, CONCEITOS E FERRAMENTAS

NATAL
2025

VÍTOR GABRIEL LEMOS LOPES

MACHINE LEARNING OPERATIONS, CONCEITOS E FERRAMENTAS

Monografia apresentada ao curso de graduação em engenharia de telecomunicações, da Universidade Federal do Rio Grande do Norte, como requisito parcial à obtenção do título de Bacharel em engenharia de telecomunicações.

Orientador: Prof. Dr. Hertz Wilton de Castro Lins.

NATAL

2024



Esta obra está licenciada com uma licença *Creative Commons* Atribuição 4.0 Internacional. Permite que outros distribuam, remixem, adaptem e desenvolvam seu trabalho, mesmo comercialmente, desde que creditem a você pela criação original. Link dessa licença: creativecommons.org/licenses/by/4.0/legalcode

Espaço destinado a ficha catalográfica. Deve ser solicitada via SIGAA. Acesse o menu Biblioteca > Serviços ao usuário > Serviços diretos > Ficha catalográfica. Ao receber a ficha, realize o *download* em PDF/A e anexe ao trabalho com todas as informações contidas na página, inclusive os dados do(a) bibliotecário(a).

VÍTOR GABRIEL LEMOS LOPES

MACHINE LEARNING OPERATIONS, CONCEITOS E FERRAMENTAS

Monografia apresentada ao curso de graduação em engenharia de telecomunicações, da Universidade Federal do Rio Grande do Norte, como requisito parcial à obtenção do título de Bacharel em engenharia de telecomunicações.

Aprovada em: ____/____/____

BANCA EXAMINADORA

Prof. Dr. Hertz Wilton de Castro Lins

Orientador(a)

UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE

Prof. Dr. Adaildo Gomes D'Assunção

Membro interno

UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE

Profa. Dra. Cristhianne Linhares de Vasconcelos

Membro interno

UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE

Dedico esse trabalho aos meus pais, Zoraide e Humberto Lamarque que tanto me ajudaram e me deram apoio financeiro e psicológico durante toda a jornada e fizeram de tudo para eu não desistir.

AGRADECIMENTOS

Agradeço aos meus pais, Humberto Lamarque Lopes e Zoraide Pegado Lemos Lopes, pelo incentivo, pelo apoio emocional e financeiro, por todos os sacrifícios que fizeram durante toda a minha jornada, pelo maior exemplo de força, honestidade e valores na vida. E à minha irmã Larissa Gabriela Lemos Lopes, a qual me apoiou e me incentivou a continuar essa jornada.

O meu orientador Hertz Wilton de Castro Lins, por guiar meus passos e possibilitado o êxito na conclusão deste trabalho, pelos ensinamentos ao longo do curso e pela coragem de me aceitar como orientando nesse curto prazo em que estivemos juntos. Tenho por ele minha sincera gratidão.

Ao meu grupo de amigos que estão todos os dias comigo e me ajudaram muito em uma época que mais estava isolado, fazendo eu ter perseverança na conclusão deste trabalho.

Agradeço à minha namorada, Raiane Oliveira Costa, a pessoa que mais me motivou em meu crescimento pessoal e profissional, um raio de sol em minha vida, que vibra com minhas conquistas como se fossem suas. Agradeço-lhe também pela inspiração em ser uma pessoa forte e dedicada, sempre buscando conhecimento e especialização em sua área, e por me incentivar a não desistir dos meus sonhos.

Agradeço à minha psicóloga, Rosa Cleide Abilio Vieira Frei, por ter ouvido minhas dores e medos, por me encorajar a realizar este trabalho, por me ajudar a reconhecer minhas qualidades e por me orientar nesse processo.

Agradeço à Universidade Federal do Rio Grande do Norte pela oportunidade de vivenciar o ensino superior, construir amizades, conhecer o mercado profissional e aprofundar meus conhecimentos sobre as novas tecnologias no curso de Engenharia de Telecomunicações.

“A primeira regra de qualquer tecnologia utilizada nos negócios é que a automação aplicada a uma operação eficiente aumentará a eficiência. A segunda é que a automação aplicada a uma operação ineficiente aumentará a ineficiência.”

Bill Gates

RESUMO

A crescente adoção de Machine Learning (ML) em diversas áreas têm impulsionado a necessidade de soluções eficientes para gerenciar o ciclo de vida dos modelos em produção. O Machine Learning Operations (MLOps) surge como uma resposta a essa demanda, combinando práticas de desenvolvimento de software (DevOps) com as particularidades do ML. O MLOps visa automatizar, integrar e monitorar as etapas do desenvolvimento, implantação e manutenção de modelos, desde a coleta e preparação de dados até o monitoramento contínuo em produção. Essa abordagem busca otimizar a performance dos modelos, garantir a reprodutibilidade dos experimentos e facilitar a escalabilidade das soluções de ML, permitindo que as organizações obtenham o máximo valor de seus investimentos em inteligência artificial.

Este estudo concentra-se na investigação do ecossistema MLOps, buscando compreender seus conceitos fundamentais e analisar as principais ferramentas utilizadas na construção e gerenciamento de pipelines de ML em produção. A pesquisa, de natureza descritiva, combina revisão bibliográfica com a análise comparativa de ferramentas, abordando a origem e evolução do MLOps, seus princípios essenciais e os desafios de sua implementação. O estudo investiga a aplicação do MLOps em setores como Indústria 4.0, saúde e cidades inteligentes, e detalha o conceito de pipelines de MLOps, desde a ingestão de dados até o monitoramento contínuo de modelos, destacando a importância de práticas de CI/CD. A pesquisa analisa as principais ferramentas disponíveis no mercado, descrevendo suas funcionalidades, arquiteturas, casos de uso, vantagens e desvantagens, com o objetivo de fornecer uma visão abrangente do ecossistema MLOps e um panorama das ferramentas disponíveis.

Palavras-chave: MLOps; aprendizado de máquina; implantação contínua; pipeline

ABSTRACT

The increasing adoption of Machine Learning (ML) in various fields has driven the need for efficient solutions to manage the lifecycle of models in production. Machine Learning Operations (MLOps) emerges as a response to this demand, combining software development practices (DevOps) with the specific characteristics of ML. MLOps aims to automate, integrate, and monitor the stages of model development, deployment, and maintenance, from data collection and preparation to continuous monitoring in production. This approach seeks to optimize model performance, ensure the reproducibility of experiments, and facilitate the scalability of ML solutions, allowing organizations to obtain maximum value from their investments in artificial intelligence.

This study focuses on investigating the MLOps ecosystem, seeking to understand its fundamental concepts and analyze the main tools used in the construction and management of ML pipelines in production. The research, of a descriptive nature, combines a literature review with a comparative analysis of tools, addressing the origin and evolution of MLOps, its essential principles, and the challenges of its implementation. The study investigates the application of MLOps in sectors such as Industry 4.0, healthcare, and smart cities, and details the concept of MLOps pipelines, from data ingestion to continuous model monitoring, highlighting the importance of CI/CD practices. The research analyzes the main tools available on the market, describing their functionalities, architectures, use cases, advantages, and disadvantages, with the objective of providing a comprehensive view of the MLOps ecosystem and an overview of the available tools.

Palavras-chave: MLOps; machine learning; continuous deployment; pipeline

LISTA DE FIGURAS

Figura 1 - Diagrama de fluxo da pesquisa	16
Figura 2 - Ciclo de vida MLOps	23
Figura 3 - fluxo de desenvolvimento ML.....	24
Figura 4 - Modelo de processo para o desenvolvimento de software	25

LISTA DE TABELAS

Tabela 1 - Vantagens e desvantagens	32
Tabela 2 - Síntese das ferramentas	33
Tabela 3 - Relação conceito com ferramentas	34

LISTA DE SIGLAS

CI	Continuous Integration
CD	Continuous Delivery
CD	Continuous Deployment
DevOps	Development and Operations
IA	Inteligência Artificial
ML	Machine Learning
MLOps	Machine Learning Operations
PLN	Processamento de Linguagem Natural
SDA	Software-Defined Assets

SUMÁRIO

1 INTRODUÇÃO.....	13
1.1 Objetivos.....	15
1.1.1 Objetivo geral	15
1.1.2 Objetivo específico	15
2 Metodologia.....	16
3 CONCEITOS.....	18
3.1 MLOPS	18
3.2 CI/CD.....	20
3.3 Pipeline.....	21
4 FERRAMENTAS.....	26
4.1 APACHE AIRFLOW	26
4.2 KUBEFLOW.....	26
4.3 DAGSTER	28
4.4 METAFLOW	28
4.5 MLFLOW	29
4.6 PREFECT	29
4.7 ZENML	30
4.8 MINERVA	30
5 RESULTADOS	32
6 CONSIDERAÇÕES FINAIS.....	35
REFERÊNCIAS	37

1 INTRODUÇÃO

A Inteligência artificial(IA) tem revolucionado em vários setores ao redor do mundo como, por exemplo, na área da saúde com a IA auxiliando na identificação de doenças, nas finanças com detecção de fraudes, no varejo com recomendação de produtos, na manufatura com a automação com robôs e máquinas inteligentes, no transporte com veículos autônomos e no entretenimento com o desenvolvimento de jogos com robôs mais inteligentes. E nessas áreas de aplicação se dá a técnicas de Inteligência artificial como o processamento de linguagem natural (PLN) que é usado nos tradutores automáticos como o do google, visão computacional que é responsável na identificação de objetos, pessoas e rostos e também o aprendizado de máquina que por exemplo pode ser redes neurais artificiais ([LUDERMIR, 2021](#)), e neste trabalho o foco está na inteligência artificial no contexto do aprendizado de máquina.

O aprendizado de máquina (Machine Learning - ML) é uma subárea da IA que utiliza conhecimento especializado para resolver problemas como, por exemplo, a análise preditiva e otimização de processos, e isso se dá através por meio de dados que compõem exemplos que são utilizados para treinamento dos modelos. E com base nos dados e exemplos que são disponibilizados ao sistema de ML, esses sistemas aprendem ou melhoram o desempenho do mesmo ([ORACLE, \[s.d.\]](#)). O uso de ML para solucionar problemas nem sempre é fácil e precisa de alguns pré-requisitos. Muitas vezes a base de exemplos precisa ser construída e atualizada constantemente. Como os dados nem sempre são adequados o suficiente para o treinamento dos modelos, faz-se necessário o uso de técnicas que melhorem a qualidade dos dados. ([LUDERMIR, 2021](#)).

E com o intuito de desenvolver produtos que utilizam ML e trazê-los para produção é altamente desafiador automatizar e operacionalizar sistemas de ML e muitos esforços falham em atender as expectativas ([KREUZBERGER; KÜHL; HIRSCHL, 2023](#)). O Machine learning operations (MLOps) é um forte candidato a padronizar os métodos de produção utilizando ML, que podem ser compreendidos como um processo iterativo de levar os melhores modelos de ML mais recentes para produção, e isso se faz com automação, integração e monitoramento em vários estágios de um sistema de ML, incluindo treinamento, integração, teste, nova versão, implementação e gerenciamento de infraestrutura([TESTI et al., 2022](#)).

O MLOps é uma metodologia inspirada nas práticas de DevOps, voltada para otimizar e integrar processos no ciclo de vida de ML. DevOps é uma prática popular no

desenvolvimento e operação de sistemas de software de larga escala. Essa prática fornece benefícios como encurtamento dos ciclos de desenvolvimento, aumento da velocidade de implantação e versionamento de modelos confiáveis. Para atingir esses benefícios, é introduzido dois conceitos no desenvolvimento do sistema de software que são integração contínua e entrega contínua ou também conhecidos em inglês como continuous integration e continuous delivery (CD)([KAZMIERCZAK; SALAMA; HUERTA, 2024](#)).

O MLOps além de uma automação de processos também é uma infraestrutura robusta que dá suporte e acompanha o ciclo de vida do modelo ML. Essa infraestrutura fornece ferramentas e padroniza fluxos de trabalho, do desenvolvimento até a produção. Um componente necessário é o pipeline de MLOps que permite tarefas como coleta, limpeza, e transformação de dados, treinamento e a avaliação de modelos, além da gestão e da implementação em ambientes de produção.

Um papel crucial do pipeline de MLOps é a adaptação do modelo à condições dinâmicas dos dados e dos sistemas, com o monitoramento é possível identificar um problema chamado data drift, situação o qual os dados começam a se distanciar dos dados que são usados para treinar o modelo, essa divergência reduz a eficácia do modelo, comprometendo a precisão de suas predições e exigindo ajustes ou re-treinamento periódicos do modelo. Com um pipeline automatizado é possível detectar as mudanças e também aciona rodadas de re-treinamento do modelo, assim provendo a manutenção do desempenho do sistema de produção a um nível satisfatório.

Este trabalho investiga o campo do MLOps, com foco em suas ferramentas e práticas de desenvolvimento e documentação. O trabalho está estruturado da seguinte forma: o Capítulo 2 detalha e descreve a metodologia empregada na pesquisa. O Capítulo 3 constroi a base teórica do estudo, apresentando os conceitos-chave do MLOps e revisando trabalhos acadêmicos e publicações relevantes na área. O Capítulo 4 explora as principais ferramentas do ecossistema MLOps, descrevendo suas características, funcionalidades e casos de uso. O Capítulo 5 integra os conhecimentos teóricos apresentados com as ferramentas práticas exploradas, realizando uma análise comparativa e identificando as relações entre teoria e prática. O Capítulo 6 conclui o trabalho, apresentando as considerações finais e possíveis direções para pesquisas futuras.

1.1 Objetivos

1.1.1 Objetivo geral

Investigar o ecossistema MLOps, compreendendo seus conceitos fundamentais, explorando as principais ferramentas utilizadas na construção e gerenciamento de pipelines de ML e analisar a relação da teoria e prática na aplicação de MLOps.

1.1.2 Objetivo específico

Para atingir o objetivo geral é preciso atingir alguns objetivos específicos anteriormente para que o objetivo seja alcançado que são eles:

- Realizar uma revisão da literatura sobre MLOps definindo princípios, práticas e objetivos do MLOps, abordando seus principais componentes, como automação de pipelines, gerenciamento de modelos, monitoramento, versionamento, integração contínua, entrega contínua e implementação contínua.
- Analisar a estrutura e os componentes de pipelines de ML em MLOps, examinando, através de revisão da literatura, as diferentes arquiteturas, ferramentas e metodologias empregadas na construção e de pipelines em trabalhos acadêmicos e aplicações práticas.
- Investigar usando uma pesquisa bibliográfica as principais ferramentas que estão sendo utilizadas no desenvolvimento de pipelines de MLOps descrevendo suas funcionalidades, arquiteturas e casos de uso.
- Realizar uma análise comparativa entre as ferramentas selecionadas, destacando suas vantagens e desafios de se utilizar e diferentes contextos de utilização e necessidades de cada uma com suporte das referências utilizadas.
- Relacionar os conceitos teóricos do MLOps com as ferramentas práticas exploradas, demonstrando como é relacionada a prática com o uso das ferramentas e os princípios teóricos.
- Descrever e Documentar todo o processo da pesquisa sobre MLOps seus conceitos, de todas as ferramentas selecionadas e os resultados obtidos a partir da pesquisa.

2 Metodologia

Este capítulo tem como objetivo descrever a metodologia usada na presente pesquisa, detalhando os procedimentos e técnicas utilizados para atingir os objetivos propostos. A pesquisa de forma descritiva busca compreender os ecossistemas de MLOps, suas ferramentas e a relação delas com a teoria.

Figura 1 - Diagrama de fluxo da pesquisa



fonte: Elaborado pelo autor, 2024

A pesquisa se inicia com a revisão bibliográfica a fim de estabelecer um embasamento teórico sobre o MLOps.

A Figura 1, por meio deste diagrama esquemático, sintetiza o processo metodológico adotado neste trabalho, evidenciando a lógica e a sequência das ações realizadas para alcançar os objetivos propostos.

- Com base na revisão da literatura, esta etapa teve como objetivo definir e detalhar os conceitos fundamentais do MLOps. Foram abordados em qual contexto tem sido usado, os princípios, práticas, objetivos e componentes do MLOps, como automação de pipeline, gerenciamento de modelos, monitoramento, implantação contínua, integração contínua e entrega contínua. Buscou-se estabelecer uma base teórica sólida para o entendimento do ecossistema MLOps e a análise das ferramentas.
- Também é necessário fazer uma análise sobre as principais ferramentas

disponíveis no mercado, para isso foi feito uma investigação e análise das principais ferramentas utilizadas no desenvolvimento e gerenciamento de pipelines de MLOps. Foram selecionadas várias ferramentas relevantes, considerando sua popularidade, funcionalidade e aplicabilidade em diferentes contextos. A análise de cada ferramenta ocorreu com a pesquisa de artigos técnicos, teses de mestrado e doutorado, documentação oficial, tutoriais, exemplos de uso e estudos de caso. O foco principal foi descrever suas funcionalidades, arquiteturas, casos de uso, vantagens e desafios encontrados no uso de cada ferramenta, com objetivo de ter uma visão sobre como as ferramentas podem melhorar no desenvolvimento dos pipelines MLOps.

Espera-se que este trabalho contribua para o entendimento do ecossistema MLOps e auxilie profissionais e pesquisadores na escolha e utilização das ferramentas mais adequadas para seus projetos.

3 CONCEITOS

Este capítulo conceitual apresenta os fundamentos teóricos e práticos do MLOps, essenciais para a compreensão deste trabalho. Serão explorados a origem e a evolução do MLOps, o funcionamento de seus pipelines, seus principais benefícios e as áreas de aplicação. A compreensão desses conceitos fornecerá a base necessária para a análise e discussão dos resultados apresentados nos capítulos subsequentes.

3.1 MLOPS

O Machine Learning Operations (MLOps) que evoluiu do DevOps junto com o Machine Learning (ML), surgiu para enfrentar problemas específicos que surgiram em decorrência da implantação de ML em uma escala cada vez maior. Enquanto o DevOps foi projetado para unificar desenvolvimento e operações em software, o MLOps inclui práticas voltadas para dados e modelos, com a junção disso, MLOps evoluiu a partir de princípios de DevOps, adaptados para integrar o ML em operações escaláveis. Estudos destacam como frameworks de MLOps permitem prever mercados complexos, como o mercado de eletricidade ([SUBRAMANYA; SIERLA; VYATKIN, 2022](#)). Com o aumento da quantidade de dados e a necessidade de re-treinamento frequente dos modelos de ML foram os principais motivos para a adoção do MLOps. Essa tecnologia foi essencial para garantir que as empresas pudessem aproveitar os benefícios do ML, mesmo em ambientes de produção complexos e dinâmicos ([RECUPITO et al., 2022](#)).

MLOps é um conjunto de práticas que integram os ciclos de vida de modelos de ML com os princípios do DevOps, incorporando práticas de engenharia de dados¹ e ciência de dados², e que busca resolver problemas inerentes ao uso de ML em produção como a escalabilidade, reprodutibilidade, monitoramento contínuo e atualização contínua de modelos. Diferentemente do ciclo tradicional de desenvolvimento de software, em que o código é a principal preocupação, no MLOps, os dados e os modelos desempenham um papel central, exigindo processos específicos para lidar com a dinamicidade e a complexidade desses elementos ([LIANG et al., 2024](#)).

MLOps promove maior automação, isso com ajuda da integração contínua, entrega contínua e implantação contínua que vem do inglês Continuous Integration,

¹ Engenharia de dados: constroi e mantém a infraestrutura de dados para análise e decisões.

² Ciência de dados: obtém conhecimento mediante o uso de métodos científicos, estatísticos, computacionais e de visualização.

Continuous Deployment, Continuous Delivery (CI/CD), esses conceitos são adaptados do DevOps para suportar as particularidades do ML, permitindo um fluxo contínuo desde o treinamento inicial dos modelos até sua implantação em ambientes em produção e seu monitoramento constante. Essa estrutura permite uma resposta ágil às mudanças nos dados, garantindo uma atualização constante dos modelos para manter sua precisão e relevância ([DHAMODHARAN, 2023](#)). Esta especialidade do mundo de ML tem como objetivo resolver problemas críticos, como o gerenciamento de grande volume de dados, a automação de pipelines, governança de modelos e redução de distorções.

Os quatro principais fundamentos que sustentam o MLOps são a automação que é uma característica crucial, pois reduz a necessidade de intervenção manual em processos como treinamento, validação, implantação e re-treinamento de modelos. Com o uso de pipelines automatizados, é possível gerenciar experimentos e treinar modelos em larga escala de maneira eficiente e confiável ([MANCHANA, 2024](#)), a reprodutibilidade é outra característica fundamental, permitindo experimentos possam ser replicados e validados com as mesmas configurações de dados, modelos e parâmetros.

Isso é especialmente importante em ambientes de ML, onde pequenas variações nos dados de entrada podem levar a grandes diferenças nos resultados dos modelos ([RECUPITO et al., 2022](#)), o versionamento também é uma característica e ela garante que cada alteração nos modelos, dados e configurações seja documentada. Essa prática facilita a auditoria e o rastreamento de versões específicas, essencial para manter um alto padrão e governança de sistemas baseados em ML, especialmente em setores que são mais críticos e que demandam alto controle de mudanças ([LWAKATARE; CRNKOVIC; BOSCH, 2020](#)) e a outra grande característica fundamental é o monitoramento contínuo que é vital para o funcionamento do pipeline que com ele é possível identificar alterações nos padrões de dados ou drifts que podem afetar o desempenho de modelos, com ferramentas automatizadas, essas mudanças podem ser detectadas e rapidamente, acionando ajustes ou re-treinamentos de forma eficiente ([RANAWANA; KARUNANANDA, 2021](#)).

Os maiores desafios que o MLOps pode resolver está associado ao uso do ML em produção, um dos principais é o drift de modelo e dados, que é o que ocorre quando os dados utilizados em produção divergem significativamente dos dados de treinamento, resultando em uma redução do desempenho do modelo. Além disso, o

MLOps lida com a necessidade de gerenciamento eficiente de recursos computacionais, otimizando custos em processos como treinamento e inferência, especialmente em ambientes de grande escala ([RITZ et al., 2022](#)), outro grande desafio é padronização e a governança, que exigem sistemas auditáveis e transparentes, isso inclui o rastreamento de experimentos, o versionamento de dados e de modelos, e a documentação de decisões tomadas durante o desenvolvimento e implantação de sistemas de ML ([LWAKATARE; CRNKOVIC; BOSCH, 2020](#)).

Estudos recentes destacam que o MLOps está sendo uma das principais tecnologias para serem usadas como, por exemplo, na indústria 4.0, que é a próxima revolução industrial na manufatura, que é baseada em tecnologias digitais. Nesse cenário, o ML desempenha um papel fundamental na melhoria de processos industriais, como na manutenção preditiva e otimização da cadeia de suprimentos. Como a indústria 4.0 busca implementar o ML em larga escala para aprimorar a produção industrial, a aplicação do MLOps torna-se indispensável, ao fornecer ferramentas e práticas para gerenciar e operacionalizar soluções de ML de forma eficiente e integrada ([FAUBEL; SCHMID; EICHELBERGER, 2022](#)).

Outros estudos mostram a aplicação de MLOps em setores como saúde com os aparelhos vestíveis que continuamente fazem a coleta de dados ajudam na predição mais precisa, é possível prever ataques cardíacos e monitoramento de obesidade em tempo real, e com a coleta contínua de dados dos aparelhos vestíveis, o sistema consegue perceber quando tem um desvio dados e fazer um novo treinamento de dados fazendo assim um monitoramento mais preciso de riscos a saúde ([DEVARAPU et al., 2019](#)). Também é possível o uso do MLOps em cidades inteligentes, como por exemplo na gestão inteligente do tráfego, estacionamento inteligente, serviços de segurança pública, eficiência energética, turismo inteligente, serviços de saúde pública e outras possibilidades, tudo isso pode ser feito usando frameworks de MLOps com microsserviços ([URIAS; ROSSI, 2023](#)).

3.2 CI/CD

A integração contínua, entrega contínua e implantação contínua formam a espinha dorsal para o funcionamento do MLOps, permitindo o desenvolvimento, treinamento e implantação de modelos de ML de maneira eficiente e escalável. Essas práticas originadas do DevOps, foram adaptadas para atender às especificidades do

ciclo de vida de ML, onde os dados e os modelos desempenham um papel central ([LIANG et al., 2024](#)).

A integração contínua (CI) é a prática de integrar alterações frequentes no código em um repositório compartilhado, como por exemplo o GIT. Em MLOps, CI não é apenas código mas também são dados, scripts de pré-processamento e modelos. Durante o processo de CI, cada mudança no código é testada automaticamente para garantir que não ocorram regressões. Isso inclui testes unitários, de integração e, em casos específicos, validações de desempenho de modelos ([JANI, 2023](#)). O CI no MLOps melhora a colaboração entre equipes multidisciplinares, a qualidade geral do código e garante a rápida incorporação de mudanças no pipeline ML. Essa prática reduz conflitos entre desenvolvedores e cientistas de dados ao permitir validações automáticas e rastreamento de mudanças ([RECUPITO et al., 2022](#)).

A entrega contínua (CD) vai além da integração contínua ao incluir automação de processos que levam o código e os modelos treinados até ambientes de teste e produção. Durante a entrega contínua, os modelos são validados em ambientes simulados antes de serem disponibilizados em produção, isso inclui a verificação de integridade dos dados e a avaliação de métricas de desempenho ([RECUPITO et al., 2022](#)). O CD garante que os artefatos estejam prontos para serem implantados a qualquer momento, eliminando atrasos por intervenções manuais ([LIANG et al., 2024](#)).

A implantação contínua (CD) é quando a automatização é maior do que na entrega contínua, garantindo que cada mudança aprovada seja automaticamente implantada no ambiente em produção como por exemplos os modelos são automaticamente substituídos por versões mais recentes, desde que atendam aos critérios de desempenho ([RECUPITO et al., 2022](#)).

3.3 Pipeline


Os pipelines de MLOps desempenham um papel crucial na automação, gerenciamento e monitoramento do ciclo de vida de ML, possibilitando o desenvolvimento e a implantação de modelos de forma escalável e eficiente. Eles consistem em uma série de etapas interconectadas que transformam dados brutos em modelos prontos para produção, suportando a integração contínua, entrega contínua e implantação contínua (CI/CD) no ambiente de ML ([KREUZBERGER; KÜHL; HIRSCHL, 2023](#)).

A figura 2 abaixo representa os componentes principais de um pipeline MLOps que são eles:

- Ingestão de dados: o primeiro estágio que é onde os dados são coletados e são alocados dentro do projeto.
- Limpeza de dados: é o segundo estágio onde os dados são limpos e preparados, esse processo garante a qualidade e a consistência dos dados usados para treinamento do modelo.
- Treinamento de modelos: nesta etapa, algoritmos de ML são aplicados aos dados processados para gerar modelos. A automação permite o re-treinamento contínuo com novos dados.
- Avaliação e comparação: o modelo é avaliado para garantir sua eficácia e evitar dois problemas overfitting, que é quando o modelo aprende excessivamente os dados de treinamento, resultando uma baixa performance em dados novos, e underfitting, quando o modelo é muito simplificado e não consegue aprender os padrões nos dados, resultando em baixa performance tanto em dados de treinamento quanto em dados novos. A comparação é feita entre os modelos novos e os que já estão em produção para verificar qual está com melhor performance.
- Produção ou implantação: inclui a entrega do modelo em ambientes de produção. Ferramentas gerenciam a transição eficiente entre os ambientes de desenvolvimento e produção.
- Monitoramento Contínuo: após a implantação, o desempenho do modelo é monitorado para identificar drifts de dados ou alterações que possam degradar sua eficácia.

As figuras 3 e 4 representam o quão complexo um pipeline pode ficar, mas continua seguindo os mesmos componentes principais.

Figura 2 - Ciclo de vida MLOps




Fonte: Elaborado pelo autor, 2024

A figura 3 mostra algumas etapas a mais, dentro de um mesmo processo como por exemplo o “Data Management” é equivalente a ingestão e limpeza de dados o qual foi explicado anteriormente só que na figura 3 é dividido em mais etapas. Assim sendo o “ML Modeling” sendo equivalente ao treinamento,

avaliação e comparação de modelo. E o “ML Operation” equivale à produção e monitoramento.


Figura 3 - fluxo de desenvolvimento ML



Fonte: ([LWAKATARE; CRNKOVIC; BOSCH, 2020](#))

Na figura 4 apresenta o pipeline de forma muito mais complexa mostrando todas áreas de conhecimento envolvidas no processo, que está organizado as atividades artefatos e associações em quatro áreas principais: Negócios (Business), Dados (Data), Engenharia (Engineering) e Computação (Computation), além de incluir Verificação & Validação (V&V) e Feedback.

Figura 4 - Modelo de processo para o desenvolvimento de software



Fonte: (RITZ et al., 2022)

4 FERRAMENTAS

Com a grande necessidade do uso de MLOps também é necessário um aumento da quantidade de tecnologias, e isso se deu a criação de vários frameworks que são modelos de programação que serve como base para criação de programas, e para entender o contexto atual foi um estudo com estudos acadêmicos recentes os frameworks mais populares e com suporte a comunidade usados no contexto de MLOps, esses Frameworks serão apresentados a seguir:

4.1 APACHE AIRFLOW

O Apache Airflow é um poderoso framework de código aberto feito para gerenciar e automatizar fluxos de trabalho complexos. Tem como principal uso no agendamento, monitoramento e automatizando fluxos de trabalho usando Python como linguagem de programação. O Airflow tem uma grande flexibilidade, integração com outras ferramentas e uma interface amigável para o usuário. Porém não é fácil para iniciantes por causa da curva de aprendizado ser muito íngreme e não ser ideal para o processamento de dados em tempo real. É necessário ter um bom gerenciamento de recursos computacionais por causa do Airflow consumir bastante ([THEUSCH; HEISTERKAMP; GRIGORYAN, 2024](#)). E ele também é usado amplamente por grandes empresas de renome como Adjoe, Adobe, Adyen, Big Fish Games, Dish, Experity, Onefootball, Plarium Krasnodar, RancherBySUSE, Seniorlink, Sift e Snapp ([APACHE SOFTWARE FOUNDATION, \[s.d.\]](#)).

4.2 KUBEFLOW

O Kubeflow é uma framework de código aberto e abrangente no sentido principal da sua capacidade de cobrir todas as etapas do ciclo de vida de ML, oferecendo um conjunto de ferramentas e funcionalidades que ajudam a simplificar os fluxos de trabalho de ML no Kubernetes, que é um sistema de orquestração de containers de código aberto desenvolvido pelo Google. E tem como objetivo tornar processos mais simples, portáteis e escaláveis. A abrangência do Kubeflow se estende ao suporte de diferentes frameworks de ML permitindo flexibilidade na escolha das ferramentas para cada tipo de projeto. ([THEUSCH; HEISTERKAMP; GRIGORYAN, 2024](#))

Por ser projetado para funcionar no Kubernetes, há várias vantagens de se trabalhar com o Kubeflow, como orquestração eficiente de containers, alta

disponibilidade de automação de fluxos de trabalho, otimização de recursos, capacidade de criar pipelines de ML completos, suporte a bibliotecas e frameworks de ML, a facilitação para se fazer experiências com modelos e a compatibilidade com implementação em nuvem híbrida e ambientes locais. Também há uma grande comunidade ativa de código aberto e um vasto ecossistema, assim sendo uma ferramenta com várias soluções para implantação e um bom gerenciamento de fluxos de trabalho de ML, com foco em escalabilidade, portabilidade e eficiência.([THEUSCH; HEISTERKAMP; GRIGORYAN, 2024](#))

Uma outra característica importante do Kubeflow é a sua integração com outros frameworks como o TensorFlow Extended(TFX) e o Vertex AI. Essa integração ajuda na colaboração entre diferentes plataformas e fluxos de trabalho, permitindo a combinação de diversas tecnologias para atender vários tipos de problemas dependendo das necessidades específicas de cada projeto.([THEUSCH; HEISTERKAMP; GRIGORYAN, 2024](#))

O Kubeflow também tem suas desvantagens e desafios, como a falta de documentação, flexibilidade limitada devido a dependência do Kubernetes e as dificuldades de monitoramento dentro dos clusters. Com uma curva de aprendizado íngreme, junto com a falta de suporte e de documentação torna ainda mais difícil o aprendizado. Há também uma complexidade no processo de instalação e os conflitos de dependências, que representam barreiras para o uso da plataforma. Além disso, também há problemas relacionados a gerenciamento de recursos computacionais, segurança, experiência do usuário e a necessidade de melhoria na integração com ambientes corporativos e nas prioridades de manutenção.([THEUSCH; HEISTERKAMP; GRIGORYAN, 2024](#))

E com todas essas vantagens e desvantagens muitas empresas adotaram e utilizam o Kubeflow, inclusive no Brasil segundo o site Theirstack 41 empresas utilizam, e nos Estados Unidos são mais de mil empresas e muitos outros países como Reino Unido, Índia, França, Alemanha, Canadá, Espanha, Países Baixos e Austrália, algumas dessas empresas são Agoda, Canonical, Bain & Company, Plente Group, Rokr, Okta, Ayasdi, UKG, Grupo Boticário, Seldon, JPMorgan Chase, Capital One, Experian, Affirm. ([HG INSIGHTS, \[s.d.\]](#)) ([THEIRSTACK, \[s.d.\]](#))

4.3 DAGSTER

Dagster é um framework avançado para organização de dados, projetado para criar e manipular diferentes tipos de dados, como tabelas, conjuntos de dados, modelos de ML e relatórios. Um conceito central é ativos definidos por Software, que em inglês é Software-Defined Assets(SDA). É considerado um ativo um objeto armazenado que representa conhecimento, uma tabela no banco de dados relacional, um arquivo local ou um armazenamento em nuvem ou um modelo ML.

A principal vantagem desses ativos é a capacidade de representar informações em diversos formatos e rastreá-las ao longo do ciclo de vida do pipeline, e outros benefícios são devido ao seu processo de inicialização que são cálculos sem requisitos específicos de infraestrutura, a plataforma separa distintamente sua estrutura de grafo e mecanismo de agendamento, o que possibilita a definição separada de agendamentos e sensores das configurações de pipeline. Porém há uma desvantagem é que sua comunidade é pouco desenvolvida em comparação com outros frameworks e isso pode levar a um suporte mais limitado e com menos recursos externos. Por isso poucas empresas usam e uma que usa é a SimpliSafe que continua trabalhando com Dagster ([THEUSCH; HEISTERKAMP; GRIGORYAN, 2024](#)).

4.4 METAFLOW

O Metaflow é um framework de código aberto para fluxo de trabalho, projetado para simplificar a construção e o gerenciamento de projetos de ML, IA e ciência de dados. Foi desenvolvido pela Netflix, o Metaflow foi criado por causa da complexidade de aplicações intensiva em dados e o seu gerenciamento. Além de ser um framework em Python de fácil utilização e com integração com alguns serviços de nuvem populares como AWS, Azure e GCP. ([THEUSCH; HEISTERKAMP; GRIGORYAN, 2024](#))

O framework tem inúmeros benefícios e alguns deles são o quanto é eficaz no rastreamento automático de dados importantes o qual tem múltiplas vantagens no ambiente de produção, há um suporte para a linguagem de programa R, o qual não é encontrado muito em outros frameworks e o Metaflow também possui uma interface amigável para visualização de métricas. Porém a organização de grandes projetos com Metaflow pode tornar o código confuso devido ao uso de muitos decorators(uma funcionalidade do Python que permite adicionar metadados ou configurar o

comportamento de funções e classes) ([THEUSCH; HEISTERKAMP; GRIGORYAN, 2024](#)).

Apesar disso, O Metaflow é utilizado por várias empresas como a Netflix, CNN, SAP, 23andMe, Realtor.com, REA, Coveo, Latana e centenas de outras em vários setores. ([METAFLOW, \[s.d.\]](#))

4.5 MLFLOW

O MLflow é um framework de código aberto criado pela Databricks que tem como objetivo auxiliar no desenvolvimento de todo ciclo de vida de ML, desde o desenvolvimento até a implantação. Possui muitas funcionalidades que são um sistema de rastreamento que mantém um registro dos detalhes do modelo, disponibiliza um registro de modelos para o gerenciamento de versões, também é fornecido uma ferramenta de avaliação do modelo, desenvolvimento de prompts (sequências de texto fornecidas como entrada para um modelo de linguagem, influenciando sua resposta, similar o que é usado no Chatgpt ou Gemini), auxilia na estruturação de projetos e no empacotamento de fluxos de trabalho de ML ([THEUSCH; HEISTERKAMP; GRIGORYAN, 2024](#)).

O framework apresenta vários benefícios e é possível destacar a conveniência de rastrear o desempenho do modelo, a capacidade de reproduzir diferentes versões do modelo, a facilidade de realizar modificações no ciclo de vida do modelo, a capacidade de integração do MLflow com várias ferramentas e plataformas simplificam o processo de implantação como por exemplo a integração com a AWS. Porém há alguns desafios como o compartilhamento de experimentos, ausência de um ambiente multiusuário e de recursos avançados de segurança ([THEUSCH; HEISTERKAMP; GRIGORYAN, 2024](#)).

4.6 PREFECT

Prefect é um framework avançado para gerenciamento de fluxos de trabalho que permite aos usuários criar, monitorar e responder a pipeline de dados. O framework permite a escrita de código na linguagem de programação em Python oferecendo um alto grau de flexibilidade no design do fluxo de trabalho. o Framework apresenta alguns benefícios que são um processo de instalação simples com uma instalação em uma única etapa e pacotes bem organizados, o Prefect também se destaca no rastreamento efetivo nas atualizações do fluxo de trabalho e sua interface do usuário é amigável e

acessível por meio de um painel funcional na nuvem. Porém, no Perfect ainda há muitos desafios como a comunidade de desenvolvedores não ser tão estabelecida, mas está em crescimento. ([THEUSCH; HEISTERKAMP; GRIGORYAN, 2024](#)).

Apesar disso, algumas empresas utilizam o Prefect como é o exemplo da Rec Room, EF Education First, Progressive, Cash App, Cisco, e 1password ([PREFECT, \[s.d.\]](#)).

4.7 ZENML

O ZenML é um framework voltado para MLOps flexível e gratuito, projetado para criar pipelines de ML portáteis e prontos para produção. O Framework se destaca nos fluxos de trabalho de ML, fornecendo pipeline adaptados aos dados, permitindo alguns recursos avançados como caching (mecanismo que armazena os resultados de etapas de um pipeline para evitar recomputação desnecessárias, economizando tempo e recursos) e lineage (rastreamento da origem e transformação dos dados e artefatos ao longo do pipeline, garantindo a rastreabilidade e reprodutibilidade dos experimentos), também é garantido que as etapas e os artefatos sejam padronizados, automatiza a criação de objetos frequentemente usados, como na linguagem de programação Python os dataframes da biblioteca Pandas e outros módulos da biblioteca PyTorch, fazendo assim ser mais amigável por quem tem mais experiência nas bibliotecas de ciências de dados.

Além disso, o ZenML é projetado para funcionar em conjunto com outros frameworks diferentes, como o Apache Airflow e Kubeflow, fazendo assim ser mais flexível. Apesar disso, o ZenML também apresenta certas limitações, especialmente quando se trata de interação da comunidade em torno da correção de bugs ou possibilidades de criação de novos recursos ([THEUSCH; HEISTERKAMP; GRIGORYAN, 2024](#)).

4.8 MINERVA

Minerva é um framework proposto por ([DUVVURI, 2020](#)) e foi usado por brasileiros da USP ([URIAS; ROSSI, 2023](#)) no uso de Minerva como framework num ambiente de MLOps, e o Minerva tem como objetivo integrar algoritmos de ML com microsserviços sendo voltado para empresas que utilizam como software como serviço, ou em inglês Software as a Service(SaaS). O Desenvolvimento de algoritmos de ML do framework pode ser desenvolvido em R e em Python, podem utilizar muitas bibliotecas

de código aberto e também tem uma série de características que são importantes para a implementação de ML em SaaS, que são a reutilização de subsistemas que usam algoritmos de ML para atender os serviços, ênfase na governança de dados descentralizada, escalabilidade, performance em tempo real, treinamento offline, proteção na troca de dados, construção de microsserviços e independentes de tecnologia podendo até usar sistemas legados.

Além dessas características, também há soluções inovadoras para o sistema empresarial, com uma entrega inteligente de serviços com a característica de serem mais leves, reduzindo o impacto em sistemas e infraestruturas relacionadas, execução de algoritmos “próximo aos dados” fazendo os dados estarem no mesmo local onde os algoritmos estão sendo executados, soluções de ML “interinas” que tem compatibilidade com sistemas SaaS tradicionais, porém com uso por um período definido. ([URIAS; ROSSI, 2023](#))

Minerva é implementado em containers Docker com três camadas central, abstração e aplicação, e organiza microsserviços em subsistemas como interface de usuário, banco de dados, subsistema central e plataforma ([DUVVURI, 2020](#)). Interage com sistemas legados, orquestra treinamentos e pré-processa dados, utilizando o conceito BYOMOA (Bring Your Own Model or Algorithm) para flexibilidade na escolha de bibliotecas de ML. Em resumo, Minerva oferece integração robusta de ML em SaaS, com ênfase em reutilização, escalabilidade, performance, segurança e compatibilidade com sistemas legados ([URIAS; ROSSI, 2023](#)).

5 RESULTADOS

Este capítulo apresenta os resultados da análise comparativa dos principais frameworks de MLOps, conectando conceitos teóricos discutidos anteriormente com as ferramentas práticas disponíveis no mercado. As tabelas a seguir apresentam uma compreensão dos aspectos referentes às ferramentas de MLOps, com uma organização estruturada das informações analisadas ao longo do trabalho. Dessa forma, elas resumem os principais pontos fortes e fracos das ferramentas, suas características relevantes e a relação entre conceitos e ferramentas.

A tabela 1, intitulada “Vantagens e desvantagens” sintetiza todos pontos fortes e fracos de utilizar cada ferramenta apresentada no capítulo anterior, fornecendo uma base para a escolha da solução mais adequada às necessidades específicas de cada projeto.

Tabela 1 - Vantagens e desvantagens

Ferramenta	Vantagens	Desvantagens
Apache Airflow	Flexibilidade, integração com diversas ferramentas, interface amigável	Curva de aprendizado íngreme, não ideal para processamento de dados em tempo real, alto consumo de recursos computacionais
Kubeflow	Abrangência no ciclo de vida de ML, integração com Kubernetes, suporte a diferentes frameworks de ML	Falta de documentação, dependência do Kubernetes, complexidade na instalação, curva de aprendizado íngreme
Dagster	Organização avançada de dados, suporte a ativos definidos por software, separação clara entre estrutura de grafo e agendamento	Comunidade pouco desenvolvida, suporte limitado
Metaflow	Facilidade de uso, integração com serviços de nuvem, rastreamento automático de dados, suporte a R	Código pode se tornar confuso em projetos grandes devido ao uso de muitos decorators
MLflow	Rastreamento de desempenho do modelo, reprodução de versões, integração com várias ferramentas e plataformas	Desafios no compartilhamento de experimentos, ausência de ambiente multiusuário, recursos avançados de segurança limitados
Prefect	Instalação simples, rastreamento eficaz de atualizações, interface amigável	Comunidade em crescimento, suporte limitado para pipelines complexos
ZenML	Flexibilidade, suporte a pipelines portáteis, integração com outros frameworks	Comunidade limitada, suporte restrito para correção de bugs e novos recursos
Minerva	Integração robusta de ML em SaaS, reutilização de subsistemas, escalabilidade, compatibilidade com sistemas legados	Comunidade limitada, documentação escassa, uso restrito a ambientes específicos

Fonte: Elaborado pelo autor, 2024

A Tabela 2, Síntese de ferramentas, apresenta todas as características relevantes de cada framework. O objetivo desta tabela é fornecer um guia prático para a escolha da ferramenta mais apropriada, considerando as particularidades de cada projeto, como volume de dados, infraestrutura disponível, experiência da equipe e objetivos de negócio.

Tabela 2 - Síntese das ferramentas

Ferramentas	Linguag em Principal	Foco Principal	Escala bilidad e	Curva de Aprendiz ado	Integração com Cloud	Casos de Uso Típicos	Empresas que utilizam
Apache Airflow	Python	Orquestração de fluxos de trabalho	Média	Alta	Alta	Agendamento e automação de tarefas complexas	Adobe, Adyen, Snapp
Kubeflow	Python	Gerenciament o de ciclo de vida de ML	Alta	Alta	Alta (nativo com Kubernetes)	Pipelines e treinamentos escaláveis	JPMorgan Chase, Grupo Boticário, Capital One
Dagster	Python	Gestão de ativos e fluxos de dados	Média	Média	Média	Gestão de pipelines para ciência de dados	SimpliSafe
Metaflow	Python, R	Fluxos de trabalho para ML e ciência de dados	Média	Baixa	Alta	Criação e implantação de projetos de ML	Netflix, CNN, 23andMe
MLflow	Python	Gerenciament o do ciclo de vida do modelo	Alta	Média	Alta	Controle de versões e implantação de modelos	Databricks, AWS
Prefect	Python	Gerenciament o de fluxos de trabalho	Média	Baixa	Alta	Monitoramento e execução de pipelines	Cash App, Cisco
ZenML	Python	Pipelines portáteis para MLOps	Alta	Média	Média	Criação de pipelines adaptados a dados	N/D
Minerva	Python, R	Integração de ML com SaaS	Alta	Alta	Média	Gerenciamento de microserviços para SaaS	Aplicações específicas em SaaS

Fonte: Elaborado pelo autor, 2024

A tabela 3 , Relação conceito com ferramentas, faz uma conexão entre o conceitos de MLOps com as melhores ferramentas para aquele tipo de conceito, os outros frameworks

podem também apresentar o conceito, mas as ferramentas citadas são as que mais se destacam na área.

Tabela 3 - Relação conceito com ferramentas

Conceito	Descrição	Ferramentas	Observações
Automatização de Pipelines	Criação de fluxos automatizados para treinamento, validação e implantação de modelos.	Apache Airflow, Kubeflow, Dagster, Prefect	Ferramentas como Apache Airflow e Prefect focam em fluxos gerais, enquanto Kubeflow é mais especializado no ciclo de vida completo de ML.
Orquestração de Workflows	Coordenação e execução de tarefas complexas em sequência.	Kubeflow, Apache Airflow, Dagster	Orquestração é o foco principal de ferramentas como Kubeflow e Dagster, com forte integração em ambientes Kubernetes.
Escalabilidade	Capacidade de lidar com um grande volume de dados ou múltiplos modelos em diferentes ambientes.	Kubeflow, MLflow, ZenML	Kubeflow é ideal para ambientes de grande escala com Kubernetes, enquanto MLflow e ZenML oferecem suporte limitado, mas adequado a projetos médios.
Monitoramento e Governança	Monitoramento do desempenho dos modelos e rastreamento do histórico de versões.	MLflow, ZenML, Metaflow	MLflow se destaca pelo registro de experimentos, enquanto Metaflow oferece integração de visualização.
Reprodutibilidade	Garantia de que os experimentos possam ser reproduzidos com os mesmos resultados.	MLflow, ZenML, Prefect	ZenML e MLflow possuem funcionalidades robustas de caching e rastreamento, que auxiliam diretamente na reprodutibilidade.
Integração com Sistemas Legados	Capacidade de integrar ferramentas modernas com sistemas antigos e soluções empresariais já existentes.	Minerva	Minerva é projetado com foco em compatibilidade com sistemas legados e SaaS.
Facilidade de Uso	Interface amigável e curva de aprendizado para desenvolvedores e cientistas de dados.	Prefect, Metaflow	Prefect tem uma interface intuitiva, enquanto Metaflow é elogiado por sua simplicidade no Python.
Colaboração em Equipe	Funcionalidades que facilitam o trabalho colaborativo em projetos de ML.	MLflow, ZenML	MLflow oferece funcionalidades básicas de compartilhamento, mas ainda apresenta limitações em ambientes multiusuários.

Fonte: Elaborado pelo autor, 2024

6 CONSIDERAÇÕES FINAIS

Este trabalho teve como objetivo principal explorar os conceitos fundamentais do MLOps e apresentar uma análise comparativa entre as principais ferramentas disponíveis no mercado para implementação de práticas eficientes de ML em produção. Ao longo dos capítulos foi abordado todo o processo de funcionamento do ciclo de vida de ML, e todas etapas que fazem parte do ciclo de vida, também foram abordados conceitos essenciais que fazem parte do MLOps, buscou-se, também, fornecer um panorama abrangente das ferramentas que auxiliam em todo o processo e ciclo de vida de ML, com intuito de facilitar a adoção de MLOps em diferentes contextos.

Os objetivos da pesquisa foram plenamente alcançados, seguindo a metodologia descrita no trabalho. a revisão bibliográfica permitiu uma base teórica sólida sobre o MLOps abordando a origem, evolução, princípios, os desafios que são resolvidos com a tecnologia e a aplicação em diversos setores. Com os princípios de MLOps, tal como pipelines e CI/CD, bem estabelecidos forneceu um contexto sobre como funcionam as ferramentas e permitiu uma análise melhor sobre.

A investigação das ferramentas do ecossistema de MLOps, resultou numa análise detalhada dos frameworks e foram descritas suas funcionalidades, arquiteturas, casos de uso, vantagens e desvantagens. As tabelas feitas no capítulo de resultados ajudam a sintetizar todas as informações, facilitando a compreensão e comparação entre as ferramentas e auxilia na escolha mais adequada para cada contexto. Na análise comparativa foi revelado a diversidade de opções disponíveis, com diferentes ferramentas atendendo a necessidades específicas dependendo do tipo de projeto, e também foi observado uma predominância da linguagem de programação em Python no ecossistema.

A contribuição deste trabalho é sintetizar o avanço do conhecimento em MLOps, fornecendo uma base teórica robusta com múltiplas referências na área contextualizando sua importância no desenvolvimento e soluções MLOps, também foi oferecido um guia prático para seleção de ferramentas com as tabelas apresentadas no capítulo de resultados e também de mostrar a relação entre a teoria e a prática com o conceito teóricos com a análise das ferramentas demonstrando os princípios do MLOps são aplicados na prática.

Como sugestão para trabalhos futuros, propõe-se a realização de estudos de caso práticos, aplicando as ferramentas citadas em diferentes cenários e avaliando

seus resultados em contextos reais. Colocar em prática as ferramentas em cenários reais em diferentes setores e ver como impacta o setor seja em saúde, finanças, cidades inteligentes ou em outros setores que podem ser utilizados. Além disso, este trabalho demanda de uma atualização contínua devido a atualizações das ferramentas já existentes e de novas ferramentas que surgem no mercado.

Em suma, este trabalho cumpriu seu objetivo de explorar os conceitos de MLOps e apresentar as ferramentas mais relevantes do mercado e mostrar todas suas características. Acredita-se que as informações e análises apresentadas contribuem significativamente para a disseminação do conhecimento na área e auxilia na escolha de ferramentas mais eficientes para o projeto desejado. Espera-se que este trabalho sirva como um recurso valioso para a comunidade acadêmica, facilitando a adoção de MLOps e impulsionando o sucesso de projetos de ML, respondendo a demanda por soluções robustas e escaláveis para operacionalizar modelos de ML.

REFERÊNCIAS

APACHE SOFTWARE FOUNDATION. **Use Cases**. Disponível em: <<https://airflow.apache.org/use-cases/>>. Acesso em: 13 dez. 2024.

DEVARAPU, K. et al. MLOps-Driven Solutions for Real-Time Monitoring of Obesity and Its Impact on Heart Disease Risk: Enhancing... **ABC Journals**, 13 maio 2019.

DHAMODHARAN, B. Driving Business Value with AI: A Framework for MLOpsdriven Enterprise Adoption. **International Journal of Sustainable Development in Computing Science**, v. 5, n. 4, out. 2023.

DUVVURI, V. **Minerva: A Portable Machine Learning Microservice Framework for Traditional Enterprise SaaS Applications**. 6th International Conference on Natural Language Processing (NATP 2020). **Anais...**Aircc Publishing Corporation, 25 abr. 2020. Disponível em: <<https://doi.org/10.5121/csit.2020.100410>>. Acesso em: 18 dez. 2024.

FAUBEL, L.; SCHMID, K.; EICHELBERGER, H. **Is MLOps different in Industry 4.0? General and Specific Challenges**. Proceedings of the 3rd International Conference on Innovative Intelligent Industrial Production and Logistics. **Anais...**SCITEPRESS - Science and Technology Publications, 2022. Disponível em: <<https://doi.org/10.5220/0011589600003329>>. Acesso em: 2 dez. 2024

HG INSIGHTS. **Companies Using Kubeflow, Market Share, Customers and Competitors**. Disponível em: <<https://discovery.hgdata.com/product/kubeflow>>. Acesso em: 17 dez. 2024.

JANI, Y. Implementing Continuous Integration and Continuous Deployment (CI/CD) in Modern Software Development. **International Journal of Science and Research (IJSR)**, v. 12, n. 6, p. 2984–2987, 5 jun. 2023.

KAZMIERCZAK, J.; SALAMA, K.; HUERTA, V. MLOps: Continuous delivery and automation pipelines in machine learning. **Google Cloud**, 28 ago. 2024.

KREUZBERGER, D.; KÜHL, N.; HIRSCHL, S. Machine Learning Operations (MLOps): Overview, Definition, and Architecture. **IEEE Access**, v. 11, p. 31866–31879, 2023.

LIANG, P. et al. Automating the training and deployment of models in MLOps by integrating systems with machine learning. **Applied and Computational Engineering**, v. 67, n. 1, p. 1–7, 31 maio 2024.

LUDERMIR, T. B. Inteligência Artificial e Aprendizado de Máquina: Estado atual e tendências. **Estudos Avançados**, v. 35, n. 101, p. 85–94, abr. 2021.

LWAKATARE, L. E.; CRNKOVIC, I.; BOSCH, J. **DevOps for AI – Challenges in Development of AI-enabled Applications**. 2020 International Conference on Software, Telecommunications and Computer Networks (SoftCOM). **Anais...IEEE**, 17 set. 2020. Disponível em: <<https://doi.org/10.23919/softcom50211.2020.9238323>>. Acesso em: 22 dez. 2024.

MANCHANA, R. The Power of Convergence: Platform Ops as the Unifying Force for DevOps, DataOps, and MLOps. **International Journal of Science and Research (IJSR)**, v. 13, n. 9, p. 51–61, 5 set. 2024.

METAFLOW. **Why Metaflow**. Disponível em: <<https://docs.metaflow.org/introduction/why-metaflow>>. Acesso em: 19 dez. 2024.

OLIST. **Brazilian E-Commerce Public Dataset by Olist**. Disponível em: <<https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>>. Acesso em: 25 nov. 2024.

ORACLE. **O que é Machine Learning?** Disponível em: <<https://www.oracle.com/br/artificial-intelligence/machine-learning/what-is-machine-learning/>>. Acesso em: 21 nov. 2024.

PREFECT. **Workflow Orchestration Made Simple**. Disponível em: <<https://www.prefect.io/>>. Acesso em: 19 dez. 2024.

RANAWANA, R.; KARUNANANDA, A. S. **An Agile Software Development Life Cycle Model for Machine Learning Application Development**. 2021 5th SLAAI International Conference on Artificial Intelligence (SLAAI-ICAI). **Anais...IEEE**, 6 dez. 2021. Disponível em: <<https://doi.org/10.1109/slaai-icai54477.2021.9664736>>. Acesso em: 22 dez. 2024.

RECUPITO, G. et al. **A Multivocal Literature Review of MLOps Tools and Features**. 2022 48th Euromicro Conference on Software Engineering and Advanced Applications (SEAA). **Anais...IEEE**, ago. 2022. Disponível em: <<https://doi.org/10.1109/seaa56994.2022.00021>>. Acesso em: 21 dez. 2024.

RITZ, F. et al. Capturing Dependencies Within Machine Learning via a Formal Process Model. In: **Lecture Notes in Computer Science**. Cham: Springer Nature Switzerland, 2022. p. 249–265.

SUBRAMANYA, R.; SIERLA, S.; VYATKIN, V. From DevOps to MLOps: Overview and Application to Electricity Market Forecasting. **Applied Sciences**, v. 12, n. 19, p. 9851, 30 set. 2022.

TESTI, M. et al. MLOps: A Taxonomy and a Methodology. **IEEE Access**, v. 10, p. 63606–63618, 2022.

THEIRSTACK. **Companies that use Kubeflow (3,040)**. Disponível em: <<https://theirstack.com/en/technology/kubeflow>>. Acesso em: 17 dez. 2024.

THEUSCH, F. T.; HEISTERKAMP, P.; GRIGORYAN, N. **Comparative Analysis of Open-Source ML Pipeline Orchestration Platforms**. Thesis—[s.l.] University of Trier, 27 mar. 2024.

URIAS, I.; ROSSI, R. Evaluation of Frameworks for MLOps and Microservices. **EAI Endorsed Transactions on Smart Cities**, v. 7, n. 3, 13 nov. 2023.